

# GENERAL PERSPECTIVE

## VARIABLES INSTRUMENTALES (IV)

# VARIABLES INSTRUMENTALES

- ▶ Las variables instrumentales **no** permiten resolver el problema de **endogeneidad** y **sesgo por variables omitidas**.
- ▶ Recordemos que si queremos ver el efecto de una variable  $Y$  en  $X$ , podemos tener que tanto  $Y$  esta correlacionada con  $X$  como  $X$  con  $Y$ .
- ▶ Además, podemos estar omitiendo variables relevantes (que no podemos controlar, por ser no observables, por ejemplo).
- ▶ Por lo tanto, recurrimos a un instrumento que este correlacionado fuertemente con la variable independiente endógena y que no este correlacionada con el error.

# VARIABLES INSTRUMENTALES: 2SLS

- Conceptualmente, la estimación por variables instrumentales se puede interpretar como dos etapas independientes de mínimos cuadrados ordinarios:

1. Primer etapa

$$X \sim Z\delta + \epsilon,$$

donde  $X$  son los predictores endógenos,  $Z$  los potenciales instrumentos y  $\epsilon$  el vector de errores. Dado la estimación de  $\hat{\delta}$ , podemos obtener  $\hat{X} = Z\hat{\delta}$ .

2. Segunda etapa

$$Y \sim \hat{X}\beta_{IV} + \mu$$

donde  $Y$  es la variable dependiente de interés y  $\mu$  es el error.

## 2SLS EN R

- ▶ Para efectos ilustrativos en R, generamos datos de 3 variables: salarios, educación y educación de los padres.
- ▶ Obsérvese que la educación de los padres es función de la variable educación.

---

```
# Creamos los datos aleatoriamente
set.seed(32)
salarios <- c(10, 10, 11, 13, 15, 18, 20, 20, 19, 21)
educacion <- c(1,1,1,2,1,2,3,3,3,3)
educacion_padres <- educacion - sample(c(0,1,2), size = 10,
                                     replace = T, prob = c(0.7,0.2,0.1))
datos_iv <- cbind.data.frame(salarios, educacion, educacion_padres)
```

---

- ▶ Podemos fácilmente estimar el coeficiente de IV utilizando `felm()` y 2SLS.

## 2SLS EN R

---

```
fs <- felm(educacion ~ educacion_padres, data = datos_iv) # first stage
datos_iv$y_hat <- fs$fitted.values # valores ajustados

ss <- felm(salarios ~ y_hat, data = datos_iv) # second stage

ss$coefficients

              salarios
(Intercept) 7.642857
y_hat       4.028571
```

---

- El coeficiente que obtenemos es el correcto, sin embargo los errores estandar estan mal.

## IV: FORMA REDUCIDA

- ▶ Noten que en la práctica no podemos tomar los *predicted values* e incorporarlos en el *second stage* ya que los errores estandar estarían mal.
- ▶ Otro camino que podemos tomar, que de igual forma nos proporciona intuición muy valiosa, es estimar la **forma reducida** (reduced form).
- ▶ La ecuación es la siguiente:

$$Y \sim Z\gamma + \epsilon,$$

## IV: FORMA REDUCIDA

- Y podemos recuperar el coeficiente de IV con el siguiente cociente:

$$\beta_{IV} = \frac{\text{Est. Reduced form}}{\text{Est. First stage}}.$$

- En R:

---

```
fs <- felm(educacion ~ educacion_padres, data = datos_iv) # first stage

rf <- rf <- felm(salarios ~ educacion_padres) # reduced form

b_iv <- rf$coefficients[2]/fs$coefficients[2]

### [1] 4.028571
```

---

## IV: FELM()

- ▶ Aunque pudimos obtener el coeficiente de IV correcto de dos formas diferentes, seguimos sin poder obtener los errores estandar correctos.
- ▶ En el caso del cociente, sacar el error estandar de una división de coeficientes se complica demasiado.
- ▶ Por lo tanto, lo que se hace siempre es utilizar paquetes y funciones ya establecidas que realizan la corrección a los errores estandar.
- ▶ Nosotros tenemos la suerte que `felm()` nos da la opción de estimar el IV de la siguiente forma:

---

```
reg_iv = felm(salarios ~ 1 | 0 | (educacion ~ educacion_padres),  
              data =datos_iv )
```

---



## IV: FELM()

- Observemos en una tabla todo lo que hemos hecho:

---

```
tableiv <- stargazer(fs, rf, ss, reg_iv,
  header = FALSE,
  font.size = "scriptsize",
  dep.var.labels.include = FALSE,
  table.placement = "H",
  omit = c("Constant"),
  column.labels = c("First Stage", "Reduced Form",
                    "2SLS", 'IV (felm)'),
  covariate.labels = c("Instrument", "IV Estimate",
                      "IV Estimate"),
  omit.stat = c("f", "ser", "adj.rsq"),
  title = "Estimación de IV",
  type = "latex")
```

---

# ESTIMACIÓN POR IV

	<i>Dependent variable: Salarios</i>			
	First Stage	Reduced Form	2SLS	IV (felm)
	(1)	(2)	(3)	(4)
Instrument	0.673*** (0.199)	2.712** (1.094)		
IV Estimate			4.029** (1.626)	
IV Estimate				4.029*** (0.921)
Observations	10	10	10	10
R <sup>2</sup>	0.589	0.434	0.434	0.818

*Note:*

\*p<0.1; \*\*p<0.05; \*\*\*p<0.01

# RELEVANCIA DEL INSTRUMENTO

- ▶ Uno de los supuestos para obtener resultados causales de la estimación por variables instrumentales es que el instrumento debe ser relevante.
- ▶ Debe estar correlacionado fuertemente con la variable endógena.
- ▶ Para ver que el supuesto se cumple, necesitamos observar un F-Stat mayor a 10.
- ▶ Noten que este no es el F de la regresión, sino más bien, el F del test de significancia del instrumento en el First Stage.
- ▶ En R:

---

```
reg_iv[["stage1"]][["iv1fstat"]][["educacion"]][["F"]]  
### [1] 11.46199
```

---

## EFECTOS FIJOS EN IV

- ▶ La función `felm()` nos proporciona con los errores estandar correctos al estimar IV.
- ▶ Noten que la diferencia no es pequeña, no utilizar `felm()` nos puede llevar a concluir erróneamente (principalmente respecto a la significancia de nuestros efectos).
- ▶ Otra gran ventaja de usar `felm()`, en lugar de otros paquetes como `ivreg()`, es que nos permite agregar efectos fijos

---

```
reg_iv_felm = felm(salarios ~ 1 | unidades + tiempo |  
                  (educacion ~ educacion_padres) | unidades,  
                  data = datos_iv)
```

```
# Y podemos acceder a los resultados usando:  
summary(reg_iv_felm, diagnostics = T)
```

---

# DOBLE INSTRUMENTO Y DOBLE VARIABLE ENDÓGENA

- ▶ En algunos proyectos, necesitaran utilizar dos instrumentos para dos variables endógenas.
- ▶ La función `felm` igual nos permite hacer esto.
- ▶ Supongamos que quisiéramos instrumentar  $Q$  y  $W$  con  $Z_3$  y  $Z_4$ . Lo que haríamos entonces sería:

---

```
reg_iv_felm = felm(salarios ~ X1 + ... + Xn | unidades + tiempo |  
                  (Q|W ~ Z3 + Z4) | unidades,  
                  data = datos_iv)
```

---

- ▶ Donde  $X_1, \dots, X_n$  son controles.